

A Configurable Approximate Multiplier for CNNs using Partial Product Speculation

Question: In applications such as AI and image processing, a large number of calculations are required, which can increase processing time, energy consumption, and hardware cost. How can we make these calculations more efficient while maintaining a good level of accuracy? Explain a suitable approach.

Answer :

A suitable approach is **Approximate Computing**, which reduces unnecessary computation while maintaining an acceptable level of accuracy.

1. **Use Approximate Computing:**

Not every calculation requires the same level of accuracy. Some calculations can be performed approximately with a small and acceptable error.

2. **Simplify Multiplication:**

In AI and image processing, multiplication is performed frequently. Instead of generating all **partial products**, some less significant partial products can be estimated or simplified.

3. **Reduce Hardware Cost:**

Fewer computations reduce **hardware area, circuit complexity, and hardware cost**.

4. **Reduce Power and Processing Time:**

Since fewer operations are performed, the system can achieve lower **power consumption and processing delay**.

5. **Use Configurable Approximation:**

The approximation level can be adjusted according to the requirement. **Less approximation** can be used when high accuracy is needed, while **more approximation** can be used when efficiency is more important.

6. **Maintain Accuracy:**

Techniques such as pre-processing or correction can be used for important cases to reduce approximation errors.

Overall, approximate computing provides a good balance between accuracy and efficiency by accepting a small, controllable error to reduce computation, power consumption, delay, and hardware cost.

AI এবং image processing-এর মতো applications-এ অনেক বেশি calculation করতে হয়, যার ফলে processing time, energy consumption এবং hardware cost বেড়ে যেতে পারে। ভালো level-এর accuracy বজায় রেখে কীভাবে এই calculations-গুলোকে আরও efficient করা যায়? একটি suitable approach ব্যাখ্যা করো।

উত্তর:

এক্ষেত্রে একটি suitable approach হলো **Approximate Computing**, যার মাধ্যমে অপ্ৰয়োজনীয় computation কমিয়ে acceptable level-এর accuracy বজায় রাখা যায়।

1. Approximate Computing ব্যবহার:

সব calculation-এর জন্য একই level-এর accuracy প্রয়োজন হয় না। তাই কিছু calculation সামান্য error গ্রহণ করে approximate করা যায়।

2. Multiplication সহজ করা:

AI ও image processing-এ multiplication অনেক বেশি ব্যবহৃত হয়। সব **partial products** তৈরি না করে কিছু less significant partial products estimate বা simplify করা যায়।

3. Hardware Cost কমানো:

কম computation করার ফলে **hardware area, circuit complexity এবং hardware cost** কমে যায়।

4. Power ও Processing Time কমানো:

কম operation করার কারণে **power consumption এবং processing delay** কমানো সম্ভব হয়।

5. Configurable Approximation ব্যবহার:

প্রয়োজন অনুযায়ী approximation-এর level পরিবর্তন করা যায়। **Accuracy বেশি প্রয়োজন হলে কম approximation এবং efficiency বেশি প্রয়োজন হলে বেশি approximation** ব্যবহার করা যায়।

6. Accuracy বজায় রাখা:

গুরুত্বপূর্ণ calculation বা input-এর ক্ষেত্রে pre-processing বা correction technique ব্যবহার করে approximation-এর error কমানো যায়।

সারসংক্ষেপে, Approximate Computing সামান্য এবং controllable error গ্রহণের মাধ্যমে computation, power consumption, processing delay এবং hardware cost কমিয়ে accuracy ও efficiency-এর মধ্যে একটি ভালো balance তৈরি করে।